BÁO CÁO ĐÁNH GIÁ

Các mẫu thiết kế Agent đặt vé máy bay

Tổng hợp số liệu CLI hiện có và đánh giá hành vi của ReAct, Plan-then-Execute, Hybrid.

Ngày tổng hợp: 06-10-2026. Mỗi kiến trúc hiện có một lượt chạy được lưu; kết luận dưới đây là quan sát ban đầu, chưa phải benchmark thống kê.

1. Kịch bản thử nghiệm

Luồng booking suôn sẻ: ReAct tìm chuyến, kiểm tra ghế, đặt, thanh toán và xác minh booking. Lượt này đạt mục tiêu theo kiểm tra của Harness.

Ngày bay không khớp constraint: Plan-then-Execute và Hybrid đều bị Harness chặn tại search_flights; không tạo booking.

Unit test riêng kiểm tra hard constraint ngày, duyệt/từ chối hành động, ngân sách, phát hiện lặp, bế tắc và tham chiếu state trong kế hoạch. Đây không phải lượt benchmark gọi LLM.

Chưa có log CLI cho tình huống ghế hết chỗ rồi chọn chuyến khác hoặc không có chuyến phù hợp; không suy diễn kết quả cho các tình huống này.

2. So sánh số liệu ghi nhận

Kiến trúc	Số lượt	Token TB	Giây TB	Bước Harness TB	Booking hợp lệ
ReAct	1	4.344	23,850	8,0	1/1 (100%)
Plan-then-Execute	1	531	3,194	1,0	0/1 (0%)
Hybrid	1	442	2,574	1,0	0/1 (0%)

Token là tổng mỗi lượt, không phải token/vòng. Số bước Harness có thể bao gồm lần xin duyệt và lần thực thi lại sau khi được duyệt; không đồng nhất với số tool call trong trace.

3. Đánh giá từng kiến trúc

A. ReAct

Thực tế: một lượt thành công, 4.344 token, 8 bước Harness, 23,850 giây; trace có search_flights, check_seat hai lần, book_seat, pay, get_booking. Harness xác minh booking.
Mạnh: quan sát mới có thể điều khiển hành động tiếp theo; phù hợp số bước không cố định.
Yếu: có thể tăng token theo lịch sử và lặp hành động. Lượt này không có loop; log chưa ghi số vòng model hoặc token từng vòng.

B. Plan-then-Execute

Thực tế: log không lưu raw plan; chỉ ghi một search_flights bị chặn do date_constraint_violation, 531 token, 3,194 giây.
Mạnh: kế hoạch cấu trúc có thể duyệt trước; lượt này có tổng token thấp.
Yếu: sai dữ liệu đầu vào có thể làm hỏng bước sau; chưa quan sát được recovery sau lỗi giữa quy trình vì booking chưa diễn ra.

C. Hybrid

Thực tế: một search_flights bị Harness chặn cùng lỗi ngày, 442 token, 2,574 giây; không có booking. Log chưa ghi nội dung review hoặc số lần replan.
Mạnh: thiết kế chia nhóm bước rồi review observation, phù hợp môi trường thay đổi.
Yếu: thêm trạng thái và lượt review khiến debug phức tạp; lượt này chưa chứng minh được khả năng phục hồi.

4. Kết luận và khuyến nghị

> **Với phiên bản và dữ liệu hiện có, ReAct là baseline duy nhất đã hoàn tất booking được Harness xác minh. Hybrid là lựa chọn đáng đánh giá tiếp cho inventory biến động, nhưng chưa có bằng chứng thành công trong lượt đã ghi. Chưa nên tuyên bố tỷ lệ thành công tổng quát từ mẫu n=1.**

Để so sánh chắc chắn hơn: dùng cùng model, constraints và inventory; chạy ít nhất 10 kịch bản, mỗi kịch bản 3 lần; lưu số lần gọi model, token theo lượt, raw plan/review đã loại dữ liệu nhạy cảm, replan count và kết quả verify_booking.